

European Luxury Real Estate · ETL Pipeline

Big Data Project — UFV · 2025-2026 · [github.com/joterojordanufv/TrabajoFinalBigData](#)

Python 3.10+

pandas · SQLAlchemy

SQLite DW

PySpark

Google Colab

Streamlit · Docker

1.026 + 180 registros

1 EXTRACT — Fuentes de Datos

extract.py · data/raw/ · tracker.py auto-log

▶ 1.206 registros brutos

Scraping

Idealista — Madrid

400 propiedades premium
CSV · data/raw/
Salamanca, Chamberí
Apartamentos, Áticos

Scraping

Rightmove — Londres

376 propiedades premium
CSV · data/raw/
Kensington, Chelsea
Flats, Houses

Scraping

Funda — Ámsterdam

250 propiedades premium
CSV · data/raw/
Jordaan, De Pijp
Appartementen

API / Dataset

Eurostat HPI

180 registros temporales
House Price Index
España · UK · NL
Series Q 2010-2024

tracker.py registra por fuente: fase · fuente · registros_entrada · registros_salida · descartados · motivo · timestamp UTC

RAW DATA → data/raw/

2 QUALITY PROFILE — Análisis Inicial de Calidad

01_edo_inicial.ipynb · pandas · df.info() · df.describe() · df.isnull().sum()

MÉTRICAS DE ESTRUCTURA

Nº registros · Nº variables
Tipos de dato (df.dtypes)
Cardinalidad categóricas

MÉTRICAS NUMÉRICAS

Outliers IQR · z-score
Rangos min / max / σ
Boxplot visual

MÉTRICAS DE CALIDAD

Nulos % · Blancos (strip)
Duplicados (df.duplicated)
Consistencia referencial

MÉTRICAS DE FORMATO

Fechas mal formateadas
Monedas con símbolo
Refs. cruzadas fuentes

Output: tabla resumen de calidad por fuente · Línea base que justifica todas las decisiones ETL posteriores

3 TRANSFORM & CLEAN — ETL · T01-T10

clean.py · 10 transformaciones obligatorias · properties_clean.csv

✓ 0 dup · nulos <2%

T01 Deduplicación

T02 Nulos

T03 Blancos

T04 Tipos

T05 Fechas ISO-8601

T06 Normalización texto

T07 Corrección rangos

T08 Outliers IQR/z-score

T09 Seudonimización PII

T10 Validación referencial

SEGMENTACIÓN LUXURY

Clasificación automática por percentil 90 del precio/m² por país → luxury_label (ES · UK · NL)

Tracking completo en pipeline_tracking.json: registros_entrada → registros_salida · descartados · motivo por cada T
Calidad mínima: nulos <2% · 0 duplicados en PK · tipos correctamente casteados · fechas ISO-8601

CLEAN DATA → data/processed/properties_clean.csv

4 EDA FINAL — Análisis Exploratorio

generate_eda_figures.py · matplotlib · seaborn · outputs/figures/

VISUALIZACIONES 001-004

G01 Heatmap nulos/correlaciones
G02 Histogramas + KDE
G03 Boxplots por ciudad
G04 Barras frecuencia barrios

VISUALIZACIONES 005-008

G05 Serie temporal precios
G06 Scatter precio vs. superficie
G07 Heatmap geográfico (opt.)
G08 Funnel tracking pipeline

Madrid

Londres

Ámsterdam

Salamanca · Chamberí

Kensington · Chelsea

+150K propiedades reales

Variables: cuantitativa continua · discreta · cualitativa nominal · ordinal · temporal · booleana
Cada gráfica con párrafo de interpretación de negocio (obligatorio para puntuar en rúbrica)

5 STAR SCHEMA — Modelo Dimensional

transform.py · Claves sustitutas (SK) · Granularidad: 1 propiedad premium europea

1 FACT · 6 DIM

FACT_PROPERTIES

price_eur · area_m2
bedrooms · price_per_m2

DIM_CITY

DIM_NEIGHBORHOOD

DIM_PROPERTY_TYPE

DIM_SOURCE

DIM_TIME

DIM_LUXURY_SEGMENT

SK enteras en todas las PK · source_id trazabilidad · load_timestamp auto-generado
CSV: dim_city · dim_neighborhood · dim_property_type · dim_source · dim_time · dim_luxury_segment · fact_properties

CSV FINALES → data/final/

6 SQL LOAD — Base de Datos SQLite

schema.sql · load.py · SQLAlchemy · real_estate_dw.db

CREATE TABLE

PK · FK · NOT NULL

Dimensiones primero

FACT después

COUNT(*) verificación

ORDEN DE CARGA (INTEGRIDAD REFERENCIAL)

1 → dim_time · dim_city · dim_neighborhood
2 → dim_property_type · dim_source · dim_luxury_segment
3 → fact_properties (con FK validadas)

Motor: SQLite · real_estate_dw.db · data/final/ · SELECT COUNT(*) en cada tabla · sin credenciales en repositorio

git push → rama main

7 EXPORT & GITHUB — Repositorio Público

github.com/joterojordanufv/TrabajoFinalBigData · rama main · Co-authored-by

data/raw/ — fuentes originales sin modificar
data/processed/ — properties_clean.csv
data/final/ — dim_*.csv · fact_properties.csv
src/ — extract.py · clean.py · transform.py · load.py · tracker.py · main.py
notebooks/ — 01_edo_inicial · 02_etl_pipeline · 03_pyspark_colab
logs/ — pipeline_tracking.json
outputs/figures/ — PNG del EDA

README.md funcional · requirements.txt · .gitignore (*.db · .env · __pycache__) · enlace obligatorio en el PDF entregable

read from raw GitHub URLs

8 PYSPARK — Google Colab · Cubo Dimensional OLAP

03_pyspark_cubo_colab.ipynb · SparkSession · cube() · rollup() · 5+ consultas

5 preguntas · 5 gráficas

OPERACIONES PYSPARK

spark.createDataFrame()
createOrReplaceTempView()
join() · groupBy() · agg()
cube() · rollup() · spark.sql()

PREGUNTAS DE NEGOCIO Q1-Q5

Q1 Evolución mensual de precios
Q2 Ranking barrios premium
Q3 Precio/m² por ciudad
Q4 Segmento luxury por país
Q5 Correlación superficie-precio

toPandas() + matplotlib para visualización · plt.savefig() exportación PNG · window functions

9 BI DASHBOARD — Streamlit + Docker

Dashboard interactivo · Dockerizado · Docker Compose · multiplataforma

Filtro: País

Filtro: Ciudad

Tipo propiedad

Luxury segment

Rango precio

Explorador SQL

Galería EDA

Comparativas internacionales

Portable · Reproducible · Sin dependencias locales · Distribución mediante Docker · outputs/figures/ PNG exportados

LEYENDA DEL PIPELINE

● Extract ● Quality Profile ● Transform & Clean ● EDA Final ● Star Schema ● SQL Load ● GitHub ● PySpark OLAP
● Dashboard T01-T10 Transformaciones ETL Q1-Q5 Preguntas PySpark